

# 尚硅谷大数据技术之 Oozie

(作者: 尚硅谷大数据研发部)

版本: V2.0

## 第1章 Oozie 简介

Oozie 英文翻译为: 驯象人。一个基于工作流引擎的开源框架,由 Cloudera 公司贡献给 Apache,提供对 Hadoop MapReduce、Pig Jobs 的任务调度与协调。Oozie 需要部署到 Java Servlet 容器中运行。主要用于定时调度任务,多任务可以按照执行的逻辑顺序调度。

## 第2章 Oozie 的功能模块介绍

### 2.1 模块

#### 1) Workflow

顺序执行流程节点,支持 fork (分支多个节点), join (合并多个节点为一个)

### 2) Coordinator

定时触发 workflow

### 3) Bundle Job

绑定多个 Coordinator

### 2.2 常用节点

### 1) 控制流节点(Control Flow Nodes)

控制流节点一般都是定义在工作流开始或者结束的位置,比如 start,end,kill 等。以及提供工作流的执行路径机制,如 decision, fork, join 等。

### 2) 动作节点 (Action Nodes)

负责执行具体动作的节点,比如:拷贝文件,执行某个 Shell 脚本等等。



## 第3章 Oozie 的部署

## 3.1 部署 Hadoop (CDH 版本的)

## 3.1.2 修改 Hadoop 配置

#### core-site.xml

### mapred-site.xml

### yarn-site.xml

完成后: 记得 scp 同步到其他机器节点

## 3.1.3 重启 Hadoop 集群

```
[atguigu@hadoop102 hadoop-2.7.2]$ sbin/start-dfs.sh
[atguigu@hadoop103 hadoop-2.7.2]$ sbin/start-yarn.sh
[atguigu@hadoop102 hadoop-2.7.2]$ sbin/mr-jobhistory-daemon.sh start historyserver
```

注意: 需要开启 JobHistoryServer, 最好执行一个 MR 任务进行测试。



## 3.2 部署 Oozie

### 3.2.1 解压 Oozie

[atguigu@hadoop102 software]\$ tar -zxvf/opt/software/cdh/oozie-4.0.0-cdh5.3.6.tar.gz -C ./

### 3.2.2 在 oozie 根目录下解压 oozie-hadooplibs-4.0.0-cdh5.3.6.tar.gz

 $[atguigu@hadoop102 \quad oozie-4.0.0-cdh5.3.6] \$ \quad tar \quad -zxvf \quad oozie-hadooplibs-4.0.0-cdh5.3.6.tar.gz -C \ ../$ 

完成后 Oozie 目录下会出现 hadooplibs 目录。

### 3.2.3 在 Oozie 目录下创建 libext 目录

[atguigu@hadoop102 oozie-4.0.0-cdh5.3.6]\$ mkdir libext/

## 3.2.4 拷贝依赖的 Jar 包

1)将 hadooplibs 里面的 jar 包,拷贝到 libext 目录下:

[atguigu@hadoop102 oozie-4.0.0-cdh5.3.6]\$ cp -ra hadooplibs/hadooplib-2.5.0-cdh5.3.6.oozie-4.0.0-cdh5.3.6/\* libext/

2) 拷贝 Mysql 驱动包到 libext 目录下:

## 3.2.5 将 ext-2.2.zip 拷贝到 libext/目录下

ext 是一个 js 框架,用于展示 oozie 前端页面:

[atguigu@hadoop102 oozie-4.0.0-cdh5.3.6]\$ cp -a /opt/software/cdh/ext-2.2.zip libext/

### 3.2.6 修改 Oozie 配置文件

#### oozie-site.xml

属性: oozie.service.JPAService.jdbc.driver

属性值: com.mysql.jdbc.Driver

解释: JDBC 的驱动

属性: oozie.service.JPAService.jdbc.url 属性值: jdbc:mysql://hadoop102:3306/oozie

解释: oozie 所需的数据库地址

属性: oozie.service.JPAService.jdbc.username

属性值: root

解释:数据库用户名

属性: oozie.service.JPAService.jdbc.password

属性值: 000000 解释: 数据库密码

属性: oozie.service.HadoopAccessorService.hadoop.configurations



属性值: \*=/opt/module/cdh/hadoop-2.5.0-cdh5.3.6/etc/hadoop

解释: 让 Oozie 引用 Hadoop 的配置文件

## 3.2.7 在 Mysql 中创建 Oozie 的数据库

进入 Mysql 并创建 oozie 数据库:

\$ mysql -uroot -p000000 mysql> create database oozie;

### 3.2.8 初始化 Oozie

### 1) 上传 Oozie 目录下的 yarn.tar.gz 文件到 HDFS:

提示: yarn.tar.gz 文件会自行解压

[atguigu@hadoop102 oozie-4.0.0-cdh5.3.6]\$ bin/oozie-setup.sh sharelib create -fs hdfs://hadoop102:8020 -locallib oozie-sharelib-4.0.0-cdh5.3.6-yarn.tar.gz

执行成功之后, 去 50070 检查对应目录有没有文件生成。

#### 2) 创建 oozie.sql 文件

[atguigu@hadoop102 oozie-4.0.0-cdh5.3.6]\$ bin/ooziedb.sh create -sqlfile oozie.sql -run

3) 打包项目, 生成 war 包

[atguigu@hadoop102 oozie-4.0.0-cdh5.3.6]\$ bin/oozie-setup.sh prepare-war

### 3.2.9 Oozie 的启动与关闭

启动命令如下:

[atguigu@hadoop102 oozie-4.0.0-cdh5.3.6]\$ bin/oozied.sh start

关闭命令如下:

[atguigu@hadoop102 oozie-4.0.0-cdh5.3.6]\$ bin/oozied.sh stop

### 3.2.10 访问 Oozie 的 Web 页面

http://hadoop102:11000/oozie

## 第4章 Oozie 的使用

## 4.1 案例一: Oozie 调度 shell 脚本

目标: 使用 Oozie 调度 Shell 脚本

分步实现:

1)解压官方案例模板

[atguigu@hadoop102 oozie-4.0.0-cdh5.3.6]\$ tar -zxvf oozie-examples.tar.gz

2) 创建工作目录

[atguigu@hadoop102 oozie-4.0.0-cdh5.3.6]\$ mkdir oozie-apps/

3) 拷贝任务模板到 oozie-apps/目录

[atguigu@hadoop102 oozie-4.0.0-cdh5.3.6]\$ cp -r examples/apps/shell/ oozie-apps

更多 Java -大数据 -前端 -python 人工智能资料下载,可百度访问: 尚硅谷官网



4) 编写脚本 p1.sh

[atguigu@hadoop102 oozie-4.0.0-cdh5.3.6]\$ vi oozie-apps/shell/p1.sh

内容如下:

```
#!/bin/bash
/sbin/ifconfig > /opt/module/p1.log
```

5) 修改 job.properties 和 workflow.xml 文件

#### job.properties

```
#HDFS 地址
nameNode=hdfs://hadoop102:8020
#ResourceManager 地址
jobTracker=hadoop103:8032
#队列名称
queueName=default
examplesRoot=oozie-apps
oozie.wf.application.path=${nameNode}/user/${user.name}/${examplesRoot}/shell
EXEC=p1.sh
```

```
<workflow-app xmlns="uri:oozie:workflow:0.4" name="shell-wf">
<start to="shell-node"/>
<action name="shell-node">
    <shell xmlns="uri:oozie:shell-action:0.2">
         <job-tracker>${jobTracker}</job-tracker>
         <name-node>${nameNode}</name-node>
         <configuration>
              property>
                  <name>mapred.job.queue.name</name>
                  <value>${queueName}</value>
              </property>
         </configuration>
         <exec>${EXEC}</exec>
         <!-- <argument>my output=Hello Oozie</argument> -->
         <file>/user/atguigu/oozie-apps/shell/${EXEC}#${EXEC}</file>
         <capture-output/>
    </shell>
    <ok to="end"/>
    <error to="fail"/>
</action>
<decision name="check-output">
    <switch>
         <case to="end">
              ${wf:actionData('shell-node')['my output'] eq 'Hello Oozie'}
         <default to="fail-output"/>
    </switch>
</decision>
<kill name="fail">
    <message>Shell
                                                               failed,
                                      action
                                                                                        error
message[${wf:errorMessage(wf:lastErrorNode())}]</message>
</kill>
<kill name="fail-output">
```



<message>Incorrect output, expected [Hello Oozie] but was
[\${wf:actionData('shell-node')['my output']}}]</message>
</kill>
<end name="end"/>
</workflow-app>

6) 上传任务配置

[atguigu@hadoop102 oozie-4.0.0-cdh5.3.6]\$ /opt/module/cdh/hadoop-2.5.0-cdh5.3.6/bin/hadoop fs -put oozie-apps//user/atguigu

7) 执行任务

[atguigu@hadoop102 oozie-4.0.0-cdh5.3.6]\$ bin/oozie job -oozie http://hadoop102:11000/oozie -config oozie-apps/shell/job.properties -run

8) 杀死某个任务

[atguigu@hadoop102 oozie-4.0.0-cdh5.3.6]\$ bin/oozie job -oozie http://hadoop102:11000/oozie -kill 0000004-170425105153692-oozie-z-W

### 4.2 案例二: Oozie 逻辑调度执行多个 Job

目标: 使用 Oozie 执行多个 Job 调度

分步执行:

1) 解压官方案例模板

[atguigu@hadoop102 oozie-4.0.0-cdh5.3.6]\$ tar -zxf oozie-examples.tar.gz

2) 编写脚本

[atguigu@hadoop102 oozie-4.0.0-cdh5.3.6]\$ vi oozie-apps/shell/p2.sh

内容如下:

#!/bin/bash

/bin/date > /opt/module/p2.log

3) 修改 job.properties 和 workflow.xml 文件

#### job.properties

```
nameNode=hdfs://hadoop102:8020
jobTracker=hadoop103:8032
queueName=default
examplesRoot=oozie-apps
```

oozie.wf.application.path=\${nameNode}/user/\${user.name}/\${examplesRoot}/shell

EXEC1=p1.sh EXEC2=p2.sh



```
<value>${queueName}</value>
                  </property>
              </configuration>
              <exec>${EXEC1}</exec>
              <file>/user/atguigu/oozie-apps/shell/${EXEC1}#${EXEC1}</file>
              <!-- <argument>my output=Hello Oozie</argument>-->
              <capture-output/>
         </shell>
         <ok to="p2-shell-node"/>
         <error to="fail"/>
    </action>
    <action name="p2-shell-node">
         <shell xmlns="uri:oozie:shell-action:0.2">
              <job-tracker>${jobTracker}</job-tracker>
              <name-node>${nameNode}</name-node>
              <configuration>
                  property>
                       <name>mapred.job.queue.name</name>
                       <value>${queueName}</value>
                  </configuration>
              <exec>${EXEC2}</exec>
              <file>/user/admin/oozie-apps/shell/${EXEC2}#${EXEC2}</file>
              <!-- <argument>my output=Hello Oozie</argument>-->
              <capture-output/>
         </shell>
         <ok to="end"/>
         <error to="fail"/>
    </action>
    <decision name="check-output">
         <switch>
              <case to="end">
                  ${wf:actionData('shell-node')['my output'] eq 'Hello Oozie'}
              <default to="fail-output"/>
         </switch>
    </decision>
    <kill name="fail">
                                                                failed,
         <message>Shell
                                         action
                                                                                       error
message[${wf:errorMessage(wf:lastErrorNode())}]</message>
    </kill>
    <kill name="fail-output">
         <message>Incorrect
                                output,
                                            expected
                                                         [Hello
                                                                    Oozie]
                                                                               but
                                                                                        was
[${wf:actionData('shell-node')['my output']}]</message>
    </kill>
    <end name="end"/>
</workflow-app>
3) 上传任务配置
$ bin/hadoop fs -rmr /user/atguigu/oozie-apps/
$ bin/hadoop fs -put oozie-apps/map-reduce /user/atguigu/oozie-apps
```

4) 执行任务

[atguigu@hadoop102 oozie-4.0.0-cdh5.3.6]\$ bin/oozie job -oozie http://hadoop102:11000/oozie -config oozie-apps/shell/job.properties -run



## 4.3 案例三: Oozie 调度 MapReduce 任务

目标: 使用 Oozie 调度 MapReduce 任务

分步执行:

- 1) 找到一个可以运行的 mapreduce 任务的 jar 包(可以用官方的,也可以是自己写的)
- 2) 拷贝官方模板到 oozie-apps

```
[atguigu@hadoop102 oozie-4.0.0-cdh5.3.6]$ cp -r /opt/module/cdh/oozie-4.0.0-cdh5.3.6/examples/apps/map-reduce/oozie-apps/
```

#### 1) 测试一下 wordcount 在 yarn 中的运行

[atguigu@hadoop102 oozie-4.0.0-cdh5.3.6]\$ /opt/module/cdh/hadoop-2.5.0-cdh5.3.6/bin/yarn jar /opt/module/cdh/hadoop-2.5.0-cdh5.3.6/share/hadoop/mapreduce/hadoop-mapreduce-examples-2. 5.0-cdh5.3.6.jar wordcount /input/ /output/

### 4) 配置 map-reduce 任务的 job.properties 以及 workflow.xml

#### job.properties

```
nameNode=hdfs://hadoop102:8020
jobTracker=hadoop103:8032
queueName=default
examplesRoot=oozie-apps
#hdfs://hadoop102:8020/user/admin/oozie-apps/map-reduce/workflow.xml
oozie.wf.application.path=${nameNode}/user/${user.name}/${examplesRoot}/map-reduce/workflow.xml
outputDir=map-reduce
```

```
<workflow-app xmlns="uri:oozie:workflow:0.2" name="map-reduce-wf">
    <start to="mr-node"/>
    <action name="mr-node">
        <map-reduce>
            <job-tracker>${jobTracker}</job-tracker>
            <name-node>${nameNode}</name-node>
            <delete path="${nameNode}/output/"/>
            </prepare>
            <configuration>
                property>
                    <name>mapred.job.queue.name</name>
                    <value>${queueName}</value>
                </property>
                <!-- 配置调度 MR 任务时,使用新的 API -->
                property>
                    <name>mapred.mapper.new-api</name>
                    <value>true</value>
                <name>mapred.reducer.new-api</name>
                    <value>true</value>
                </property>
```



```
<!-- 指定 Job Key 输出类型 -->
                property>
                    <name>mapreduce.job.output.key.class</name>
                    <value>org.apache.hadoop.io.Text</value>
                <!-- 指定 Job Value 输出类型 -->
                property>
                    <name>mapreduce.job.output.value.class</name>
                    <value>org.apache.hadoop.io.IntWritable</value>
                <!-- 指定输入路径 -->
                property>
                    <name>mapred.input.dir</name>
                    <value>/input/</value>
                <!-- 指定输出路径 -->
                property>
                    <name>mapred.output.dir</name>
                    <value>/output/</value>
                <!-- 指定 Map 类 -->
                property>
                    <name>mapreduce.job.map.class</name>
<value>org.apache.hadoop.examples.WordCount$TokenizerMapper</value>
                <!-- 指定 Reduce 类 -->
                property>
                    <name>mapreduce.job.reduce.class</name>
<value>org.apache.hadoop.examples.WordCount$IntSumReducer</value>
                </property>
                property>
                    <name>mapred.map.tasks</name>
                    <value>1</value>
                </configuration>
        </map-reduce>
        <ok to="end"/>
        <error to="fail"/>
    </action>
    <kill name="fail">
        <message>Map/Reduce
                                                  failed,
                                                                             error
message[${wf:errorMessage(wf:lastErrorNode())}]</message>
    </kill>
    <end name="end"/>
</workflow-app>
```

5) 拷贝待执行的 jar 包到 map-reduce 的 lib 目录下



[atguigu@hadoop102 oozie-4.0.0-cdh5.3.6]\$ cp -a /opt/module/cdh/hadoop-2.5.0-cdh5.3.6/share/hadoop/mapreduce/hadoop-mapreduce-examples-2.5.0-

cdh5.3.6.jar oozie-apps/map-reduce/lib 6) 上传配置好的 app 文件夹到 HDFS

[atguigu@hadoop102 oozie-4.0.0-cdh5.3.6]\$ /opt/module/cdh/hadoop-2.5.0-cdh5.3.6/bin/hdfs dfs-put oozie-apps/map-reduce/ /user/admin/oozie-apps

7) 执行任务

[atguigu@hadoop102 oozie-4.0.0-cdh5.3.6]\$ bin/oozie job -oozie http://hadoop102:11000/oozie -config oozie-apps/map-reduce/job.properties -run

## 4.4 案例四: Oozie 定时任务/循环任务

目标: Coordinator 周期性调度任务

分步实现:

- 1) 配置 Linux 时区以及时间服务器
- 2) 检查系统当前时区:

# date -R

注意:如果显示的时区不是+0800,删除 localtime 文件夹后,再关联一个正确时区的链

接过去,命令如下:

# rm -rf /etc/localtime

# ln -s /usr/share/zoneinfo/Asia/Shanghai /etc/localtime

同步时间:

# ntpdate pool.ntp.org

修改 NTP 配置文件:

# vi /etc/ntp.conf

去掉下面这行前面的#,并把网段修改成自己的网段:

restrict 192.168.122.0 mask 255.255.255.0 nomodify notrap

注释掉以下几行:

#server 0.centos.pool.ntp.org

#server 1.centos.pool.ntp.org

#server 2.centos.pool.ntp.org

把下面两行前面的#号去掉,如果没有这两行内容,需要手动添加

server 127.127.1.0 # local clock

fudge 127.127.1.0 stratum 10

重启 NTP 服务:

# systemctl start ntpd.service,

注意,如果是 centOS7 以下的版本,使用命令: service ntpd start

# systemctl enable ntpd.service,

注意,如果是 centOS7 以下的版本,使用命令:chkconfig ntpd on

集群其他节点去同步这台时间服务器时间:

首先需要关闭这两台计算机的 ntp 服务

# systemctl stop ntpd.service,

更多 Java -大数据 -前端 -python 人工智能资料下载,可百度访问: 尚硅谷官网



centOS7以下,则: service ntpd stop

# systemctl disable ntpd.service,

centOS7以下,则: chkconfig ntpd off

# systemctl status ntpd, 查看 ntp 服务状态

# pgrep ntpd, 查看 ntp 服务进程 id

同步第一台服务器 linux01 的时间:

# ntpdate hadoop102

使用 root 用户制定计划任务,周期性同步时间:

# crontab -e

\*/10 \* \* \* \* /usr/sbin/ntpdate hadoop102

重启定时任务:

# systemctl restart crond.service,

centOS7以下使用: service crond restart,

其他台机器的配置同理。

3) 配置 oozie-site.xml 文件

属性: oozie.processing.timezone

属性值: GMT+0800

解释:修改时区为东八区区时

注: 该属性去 oozie-default.xml 中找到即可

4) 修改 js 框架中的关于时间设置的代码

\$ vi /opt/module/cdh/oozie-4.0.0-cdh5.3.6/oozie-server/webapps/oozie/oozie-console.js 修改如下:

function getTimeZone() {

Ext state Manager set

Ext.state.Manager.setProvider(new Ext.state.CookieProvider()); return Ext.state.Manager.get("TimezoneId","GMT+0800");

5) 重启 oozie 服务,并重启浏览器(一定要注意清除缓存)

[atguigu@hadoop102 oozie-4.0.0-cdh5.3.6]\$ bin/oozied.sh stop [atguigu@hadoop102 oozie-4.0.0-cdh5.3.6]\$ bin/oozied.sh start

6) 拷贝官方模板配置定时任务\

\$ cp -r examples/apps/cron/ oozie-apps/

7) 修改模板 job.properties 和 coordinator.xml 以及 workflow.xml

### job.properties

nameNode=hdfs://hadoop102:8020

jobTracker=hadoop103:8032

queueName=default

examplesRoot=oozie-apps

oozie.coord.application.path=\${nameNode}/user/\${user.name}/\${examplesRoot}/cron

#start: 必须设置为未来时间, 否则任务失败

start=2017-07-29T17:00+0800

end=2017-07-30T17:00+0800

workflowAppUri=\${nameNode}/user/\${user.name}/\${examplesRoot}/cron

更多 Java -大数据 -前端 -python 人工智能资料下载,可百度访问: 尚硅谷官网



EXEC3=p3.sh

#### coordinator.xml

```
name="cron-coord"
                                        frequency="${coord:minutes(5)}"
                                                                          start="${start}"
<coordinator-app
end="${end}" timezone="GMT+0800" xmlns="uri:oozie:coordinator:0.2">
<action>
    <workflow>
        <app-path>${workflowAppUri}</app-path>
        <configuration>
             cproperty>
                 <name>jobTracker</name>
                 <value>${jobTracker}</value>
             </property>
             property>
                  <name>nameNode</name>
                 <value>${nameNode}</value>
             </property>
             property>
                 <name>queueName</name>
                 <value>${queueName}</value>
             </property>
        </configuration>
    </workflow>
</action>
</coordinator-app>
```

```
<workflow-app xmlns="uri:oozie:workflow:0.5" name="one-op-wf">
<start to="p3-shell-node"/>
  <action name="p3-shell-node">
      <shell xmlns="uri:oozie:shell-action:0.2">
           <job-tracker>${jobTracker}</job-tracker>
           <name-node>${nameNode}</name-node>
           <configuration>
                property>
                    <name>mapred.job.queue.name</name>
                    <value>${queueName}</value>
               </configuration>
           <exec>${EXEC3}</exec>
           <file>/user/atguigu/oozie-apps/cron/${EXEC3}#${EXEC3}</file>
           <!-- <argument>my output=Hello Oozie</argument>-->
           <capture-output/>
      </shell>
      <ok to="end"/>
      <error to="fail"/>
  </action>
<kill name="fail">
    <message>Shell
                                      action
                                                              failed,
                                                                                      error
message[${wf:errorMessage(wf:lastErrorNode())}]</message>
</kill>
<kill name="fail-output">
    <message>Incorrect
                            output,
                                         expected
                                                      [Hello
                                                                  Oozie]
                                                                              but
                                                                                       was
[${wf:actionData('shell-node')['my_output']}}]</message>
</kill>
```



<end name="end"/>
</workflow-app>

8) 上传配置

[atguigu@hadoop102 oozie-4.0.0-cdh5.3.6]\$ /opt/module/cdh/hadoop-2.5.0-cdh5.3.6/bin/hdfs dfs-put oozie-apps/cron//user/admin/oozie-apps

9) 启动任务

[atguigu@hadoop102 oozie-4.0.0-cdh5.3.6]\$ bin/oozie job -oozie http://hadoop102:11000/oozie -config oozie-apps/cron/job.properties -run

注意: Oozie 允许的最小执行任务的频率是 5 分钟

## 第5章 常见问题总结

1) Mysql 权限配置

授权所有主机可以使用 root 用户操作所有数据库和数据表

mysql> grant all on \*.\* to root@'%' identified by '000000'; mysql> flush privileges;

mysql> exit;

- 2) workflow.xml 配置的时候不要忽略 file 属性
- 3) jps 查看进程时,注意有没有 bootstrap
- 4) 关闭 oozie

如果 bin/oozied.sh stop 无法关闭,则可以使用 kill -9 [pid],之后 oozie-server/temp/xxx.pid 文件一定要删除。

- 5) Oozie 重新打包时,一定要注意先关闭进程,删除对应文件夹下面的 pid 文件。(可以参考第 4 条目)
- 6) 配置文件一定要生效

起始标签和结束标签无对应则不生效,配置文件的属性写错了,那么则执行默认的属性。

- 7) libext 下边的 jar 存放于某个文件夹中,导致 share/lib 创建不成功。
- 8)调度任务时,找不到指定的脚本,可能是 oozie-site.xml 里面的 Hadoop 配置文件没有关联上。
- 9) 修改 Hadoop 配置文件,需要重启集群。一定要记得 scp 到其他节点。
- 10) JobHistoryServer 必须开启,集群要重启的。
- 11) Mysql 配置如果没有生效的话,默认使用 derby 数据库。
- 12) 在本地修改完成的 job 配置,必须重新上传到 HDFS。
- 13)将 HDFS 中上传的 oozie 配置文件下载下来查看是否有错误。
- 14) Linux 用户名和 Hadoop 的用户名不一致。

更多 Java - 大数据 - 前端 - python 人工智能资料下载,可百度访问: 尚硅谷官网